Scrapy

A Fast and Powerful Scraping and Web Crawling Framework

LdPx, lammbraten, foobar999

14. Juni 2017

Übersicht

Allgemeines

- Definition Scraping...
- Was ist Web-Scraping?
- Framework für Python
- Crawlen von Websites
- Extraktion strukturierter Daten

Installation

- mit pip (erfordert vorhandene Python-Installation):

  ```
  pip3 install scrapy
  ```

- mit anaconda (in Windows einfacher, da numpy, etc... bereits enthalten):

  ```
  conda install -c conda-forge scrapy
  ```

Projekt anlegen

- Verzeichnisstruktur erzeugen:

  ```
  scrapy startproject mynewproject
  ```

- erzeugt ein gleichnamiges Verzeichnis `./mynewproject`
- künftige Spider werden in `./mynewproject/spiders` angelegt
- Konfiguration erfolgt über `./mynewproject/settings.py`

Spider

- spezielle Klassen in Scrapy-Projekten
- von Klasse `scrapy.Spider` abgeleitet
- führen Crawling durch, spezifisch für Websites programmierbar
- Ablauf:
  1. Spider schickt Requests an initiale URLs
  2. scrapy ruft je Response Callback-Methode auf, mit Inhalt als Parameter
  3. Callback-Methode startet ggf. Requests an weitere URLs
  4. Callback-Methode extrahiert Daten des Response und gibt sie zurück
  5. scrapy sammelt alle zurückgegebenen Daten ein, und speichert sie z.B. in einer Datei

einfacher Beispielspider (1)

```
import scrapy

class SimpleSpider(scrapy.Spider):
    name = 'simplespider'
    start_urls = ['http://supersimpleloremipsum.com/']

    def parse(self, response):
        self.logger.info('parsing {}'.format(response))
        yield {'status': response.status}
```

einfacher Beispielspider (2)

- `name` identifiziert den Spider eindeutig im Projekt
- `start_urls` beinhaltet die URLs für die initialen Requests
- `parse()` wird als Callback aufgerufen, der Parameter `response` enthält das Ergebnis des Response
- die Methode erzeugt eine Logging-Ausgabe von `response`
- die Methode übergibt scrapy das Parsingergebnis den HTTP-Statuscode als `dict`

einfacher Beispielspider (3)

- das Crawling mit Spider `simplespider` wird über einen eigenen Befehl in der Kommandozeile gestartet:

```
scrapy crawl simplespider -o res.json
```

- scrapy speichert die per `yield` zurückgegebenen Daten in der Datei `res.json` (das Dateiformat ergibt sich aus Suffix)
  - scrapy unterstützt neben json weitere Formate: xml, csv, ...
  - beachte: scrapy leert bei mehrfachem Start des Crawlingbefehls die Datei nicht, sondern hängt die Daten hinten dran
- Befehl auch über Pythonskript aufrufbar:

```
def main():
  cmd = 'scrapy crawl iter -o res.json'
  scrapy.cmdline.execute(cmd.split())
main()
```

- API zum Crawlen: Fehlanzeige ?

Extraktion von Daten (1)

```
def parse(self, resp):
  res1 = resp.css('div small')
  #[<Selector data='<small..."">'>, <Selector data='<
      small..."">'>, ...]
  res2 = resp.css('div small::text')
  #[<Selector data='Albert Einstein'>, <Selector data
      ='J.K. Rowling'>, ...]
  res3 = resp.css('div small::text').extract()
  #['Albert Einstein', 'J.K. Rowling', ...]
  res4 = resp.css('div small::text').extract_first()
  #Albert Einstein
  ...
```

Extraktion von Daten (2)

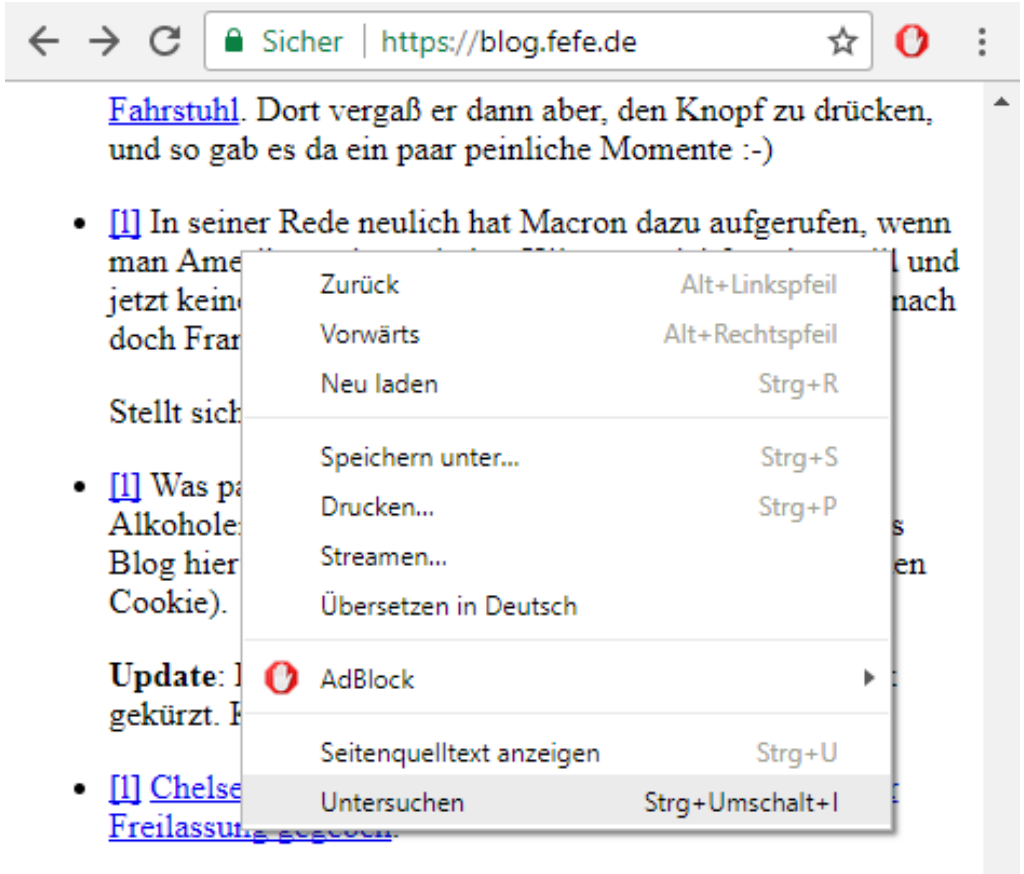

Bla Bla Bla Mr. Freeman, Caption.

Extraktion von Daten (3)

- `resp.css('div small')` selektiert mehrere Elemente im DOM mit dem CSS-Selektor `'div small'` (d.h. es findet alle `<small>`-Elemente innerhalb von `<div>`-Elementen)
- `resp.css('div small::text')` selektiert den Text innerhalb jedes gefundenen `<small>...</small>`-Tags
- `resp.css('div small::text').extract()` liefert die selektierten Texte als Liste von Python-Strings
- `resp.css('div small::text').extract_first()` liefert den 1. Treffer davon

Extraktion von Daten (4)

- das Ergebnis einer Selektion kann selbst wieder zum Selektieren genutzt werden
- folgendes Beispiel selektiert alle Zitate einer Website, und gibt je Zitat als Datensatz Autor und Wortlaut zurück:

```
def parse(self, response):
  quotes = response.css('div.quote')
  for q in quotes:
    yield {
      'author': q.css('.author::text').extract_first(),
      'text': q.css('.text::text').extract_first()
    }
```

Links folgen (1)

```
def parse(self, response):
  for q in response.css('div.quote'):
    yield {
      'text': q.css('.text::text').extract_first(),
      'author': q.css('.author::text').extract_first()
    }
  a_selector = 'li.next a::attr(href)'
  hrefs = response.css(a_selector).extract()
  for href in hrefs:
    yield response.follow(href, callback=self.parse)
```

- die Methode liefert zunächst von den Zitaten Autor und Wortlaut
- danach sucht sie alle passenden `<a href=...>`-Elemente und selektiert je Treffer das `href`-Attribut mit `'a::attr(href)'`

Links folgen (2)

- zuletzt extrahiert die Methode die enthaltenen URLs und untersucht sie rekursiv mit `response.follow(href, callback=self.parse)`
- scrapy merkt sich außerdem intern schon besuchte URLs und vermeidet so mögliche Endlosrekursionen durch wechselseitige URL-Verweise

Übung: Emails - Skynet kann das!

$\rightarrow$ *TO.BE.DONE*!

Übung: Blog-Posts

→ *Textebefreien*!*und . . . jawaseigentlich* :?

Übung: Link-counter

$\rightarrow$ *ZählenZählenZählen*!

Fazit

Ist Scrapy toll?
Vielleicht!

Quellen

[1] https://doc.scrapy.org/en/latest/intro/tutorial.html

[2] https://doc.scrapy.org/en/latest/intro/install.html

[3] https://doc.scrapy.org/en/latest/topics/spiders.html